

POLICY BRIDGE

오픈소스 LLM 10 종 통합 벤치마크 결과

기능 1 소득 추정 + 기능 2 서류 체크리스트·발급 안내

10 개

비교한 로컬 LLM

460 개

후보 답변 생성

93.7 점

안전우선 1 위 통합점수

0 건

상위 3 개 모델 중요 실패

핵심 결론

안전성 기준 1 위: Mistral Small 3.1 24B

통합점수 93.7 점, 중요 실패 0 건, 통합 트랩 평균 95.0 점으로 안전우선 순위 1 위를 기록했습니다.

실전 배포 추천: Phi-4 14B

Mistral 과 같은 통합점수 93.7 점·중요 실패 0 건이면서, 후보 답변 평균 생성시간은 18.0 초로 Mistral(48.8 초)보다 약 2.7 배 빨랐습니다.

속도 우선 대안: Llama 3.1 8B

평균 6.1 초/건으로 가장 빠른 편이면서 중요 실패 0 건, 통합점수 90.1 점을 기록했습니다.

작성일 2026-07-17 | 실행 프롬프트 policy_bridge_combined_v1

1. 평가 설계와 실행 무결성

동일 조건에서 10 개 모델을 비교하고, 정답 파일은 후보 생성 단계에서 차단했습니다.

항목	설정
평가 모델	Qwen, DeepSeek-R1, Phi-4, Gemma 3, Llama 3.1, Mistral 등 10 종
케이스 구성	기능 1 20 개 + 기능 2 26 개 = 모델당 46 개
총 후보 답변	10 개 모델 × 46 개 = 460 개
자동 채점	Qwen3 14B LLM-as-judge, 기능별 0-5 점 항목 평가
생성 조건	temperature 0.0, seed 42, context 16,384, max output 1,400 tokens
정보 누출 통제	candidate_prompt_uses_golden_outputs = false
기능 1 근거	salary_by_age.csv, salary_by_size_rank.csv 실제 참고표 첨부

실행 시간

단계	소요 시간	비고
후보 답변 생성	2 시간 38 분 48 초	2026-07-17 00:31:37 ~ 03:10:25
자동 Judge 채점	2 시간 56 분 58 초	03:11:03 ~ 06:08:01
전체 파이프라인	5 시간 36 분 24 초	리포트 집계 시간은 미미함

데이터 완전성 점검

- **후보 생성 성공:** 460 개 요청 모두 status=success 로 기록되었습니다.
- **최종 답변 공백:** 25 개 응답이 1,400 토큰 상한에 도달한 뒤 output_chars=0 으로 남았습니다. 대부분 Qwen3/DeepSeek-R1 계열의 사고 과정만 소비한 사례입니다.
- **자동 0 점 처리:** 25 개가 빈 답변으로 auto_zero 처리되었습니다.
- **Judge 파싱 실패:** 2 개(qwen3:8b 의 F1-03, T2A-09)가 JSON 파싱 실패로 집계에서 제외되어 기능 1 커버리지 95.0%, 기능 2 커버리지 96.2%가 되었습니다.

중요 해석


이번 점수는 모델 자체 성능뿐 아니라 현재 생성 설정(num_predict=1400), 사고 모드 출력 방식, JSON 준수 능력까지 포함한 “서비스 실행 성능”입니다. 특히 빈 출력은 의미 추론 실패라기보다 출력 예산·포맷 문제일 수 있으므로 재실험이 필요합니다.

자료: run_manifest.json, model_outputs.csv, scores_llm_judge.csv

2. 통합 결과

안전우선 순위는 중요 실패 건수 → 통합점수 → 트랩 평균 순으로 결정했습니다.

통합 안전우선 순위와 점수




색상: 초록=중요 실패 0건, 노랑=1-2건, 빨강=3건 이상

순위	모델	통합	기능 1	기능 2	중요 실패	평균 속도
1	mistral-small3.1:24b	93.7	88.7	98.7	0	48.8s
2	phi4:14b	93.7	88.3	99.0	0	18.0s
3	llama3.1:8b	90.1	82.8	97.4	0	6.1s
4	qwen3-coder:30b	94.4	88.8	100.0	1	19.4s
5	gemma3:12b	89.6	80.2	98.9	1	9.5s
6	qwen2.5-coder:14b	87.8	77.8	97.8	2	12.5s
7	deepseek-r1:14b	89.0	79.9	98.1	4	25.7s
8	qwen3:14b	87.8	76.3	99.4	4	31.4s
9	qwen3:8b	79.6	59.8	99.4	6	15.7s
10	deepseek-r1:8b	53.7	18.4	88.9	19	19.5s

자료: combined_report_by_model.csv, model_outputs.csv

3. 기능 1 - 가구 월소득 추정

기능 1 이 모델 간 차이를 가장 크게 드러낸 핵심 변별 구간이었습니다.



핵심 관찰

기능 1 최고점은 Qwen3-Coder 30B 의 88.8 점이지만 F1-15 가구 정의 모호성에서 중요 실패 1 건이 발생했습니다. 중요 실패 0 건 모델 중 Mistral 24B(88.7 점), Phi-4 14B(88.3 점), Llama 3.1 8B(82.8 점)가 안정적이었습니다.

반복적으로 드러난 취약점


- **가구 정의 단정:** F1-15·F1-17 에서 부모·조부모 소득의 포함 여부를 공고 확인 없이 단정하는 문제가 반복되었습니다.
- **정보 누락 처리:** F1-03·F1-18 에서 언급되지 않은 가족 구성원을 0 원으로 보거나 확인 질문을 생략하는 오류가 나타났습니다.
- **비매핑 직종 강제 연결:** F1-01 의 한의원 조무사, 자영업·프리랜서 유형을 기업 직급표에 억지로 매핑하는 문제가 평가되었습니다.
- **범위 대신 단일값:** 표 값이 정확해도 범위 요청을 단일 숫자로 확정해 감점된 사례가 다수 있었습니다.

안전 순위	모델	점수	정보부족 대응	중요 실패	트랩 평균
1	mistral-small3.1:24b	88.7	4.85	0	91.0
2	phi4:14b	88.3	4.90	0	89.8
3	llama3.1:8b	82.8	4.65	0	83.7
4	qwen3-coder:30b	88.8	4.70	1	85.9
5	gemma3:12b	80.2	4.55	1	85.0

자료: feature1_report_by_model.csv, feature1_critical_failure_cases.csv

4. 기능 2 - 서류 체크리스트·발급 안내

대부분 모델이 높은 점수를 기록해 기능 1 보다 변별력이 낮았습니다.



전장 효과

기능 2 는 상위 9 개 모델이 97.4 점 이상을 기록했고, 8 개 모델은 중요 실패 0 건이었습니다. 기능 2 프롬프트와 테스트셋이 안정적으로 작동한 결과이지만, 모델 간 미세 차이를 가리기에는 Judge 가 관대한지 추가 검증할 필요가 있습니다.

확인된 중요 실패 4 건


모델	케이스	트랩 유형	점수	요약
deepseek-r1:8b	T2A-09	mutually_exclusive_track_confusion	0	후보 모델 실행 실패 또는 빈 답변
deepseek-r1:8b	T2A-11	commonsense_override_of_source (both directions)	66	완전성: DOC_042 를 '본인 직접신청이니 불필요'로 잘못 제외(공통필수로 유지해야 함), DOC_034 를 '확인필요'로 표...
deepseek-r1:8b	T2A-12	multi_party_consent_omission	0	후보 모델 실행 실패 또는 빈 답변
deepseek-r1:14b	T2A-03	commonsense_override_of_source + urgent_info_omission	66	혼인관계증명서 누락으로 완전성 저하, 재학증명서 조건부 사항 자연스럽게 전달. 긴급 안내는 포함했으나, 혼인관계증명서 누락으로...

- **DeepSeek-R1 14B / T2A-03:** 혼인관계증명서 누락과 신청기간 긴급 정보 처리에서 오류가 발생했습니다.
- **DeepSeek-R1 8B:** T2A-09·T2A-12 는 빈 최종 답변, T2A-11 은 원본의 공통 필수 서류를 상식으로 제외했습니다.
- **기능 2 최고점:** Qwen3-Coder 30B 가 100.0 점을 기록했으며 Qwen3 14B·8B 는 99.4 점이었습니다. 다만 Qwen3 8B 는 Judge 파싱 실패 1 건으로 25/26 케이스만 집계되었습니다.

자료: feature2_report_by_model.csv, feature2_critical_failure_cases.csv

5. 모델 선정 권고

정확도만이 아니라 실패 건수, 속도, 운영 복잡도를 함께 고려했습니다.



용도	권장 모델	근거	판단
기본 배포	Phi-4 14B	통합 93.7 · 중요 실패 0 · 평균 18.0 초	24B 대비 빠르고 안정적. 현재 환경의 가장 균형 잡힌 선택
안전성 최우선	Mistral Small 3.1 24B	통합 93.7 · 트랩 95.0 · 중요 실패 0	최고 안전 순위. 다만 평균 48.8 초로 느림
속도 최우선	Llama 3.1 8B	통합 90.1 · 중요 실패 0 · 평균 6.1 초	실시간 UX 나 저사양 배포에 적합
기능 2 특화	Qwen3-Coder 30B	기능 2 100.0 · 통합 94.4	서류 안내는 최고. 기능 1 F1-15 실패 1 건 때문에 검증 로직 필요

배포 아키텍처 제안

- **기본 모델:** Phi-4 14B 를 사용합니다.
- **규칙 검증:** 소득 합산·가구원 범위·서류 OR 조건은 Python 에서 선검증합니다.
- **불확실성 게이트:** 정보 부족 시 숫자나 필수 여부를 확정하지 못하도록 강제합니다.
- **기능별 라우팅:** 서류 안내는 Llama 3.1 8B 를 빠른 경로로 사용할 수 있습니다.

최종 결론의 제한

- **Judge 편향:** Qwen3 14B 단일 Judge 이므로 사람 평가 또는 다른 Judge 와 교차 검증해야 합니다.
- **표본 크기:** 기능 1 20 개·기능 2 26 개는 실패 유형 탐지용으로는 유효하지만 정식 벤치마크로는 작습니다.
- **기능 2 천장 효과:** 상위 점수가 밀집돼 더 어려운 트랩이 필요합니다.
- **출력 예산:** 사고형 모델은 1,400 토큰을 소진하고 최종 답변이 비는 사례가 있어 설정 변경 후 재평가해야 합니다.
- **자료 노후화:** 기능 1 직급 자료는 2022 년 기준입니다.

권고 결론

Phi-4 14B 를 기본 배포 모델로 사용하고 Mistral 24B 를 고위험 재검토용으로 두는 구성이 합리적입니다. 최종 확정 전 상위 3 개 모델을 사람 평가로 재채점하고, Qwen3·DeepSeek-R1 계열은 사고 모드 설정을 수정해 재실험해야 합니다.