

Policy Bridge 임베딩 모델 × RAG 기법 종합 분석

10개 임베딩 모델과 3개 검색 방식을 비교한 결과를 품질, 속도, 통계적 신뢰성, 구현 타당성 관점에서 재검토

실험 범위 43개 질문 · 1,655개 청크 · CPU · 30개 계획 조합 중 27개 성공, GTE 3개 실패

운영 기본값

BGE-M3 + V2 Hybrid

nDCG@5 0.876 · Hit@1 74.4%
Recall@5 96.9% · P95 136.9ms

저지연 대안

KoSimCSE + V1 Dense

nDCG@5 0.847 · Hit@1 69.8%
Recall@5 96.9% · P95 40.7ms

추가 검토 후보

KR-SBERT + V2 Hybrid

nDCG@5 0.834 · Hit@1 69.8%
Recall@5 98.1% · P95 37.8ms


최종 판단

채택	BGE-M3 + V2 Hybrid를 현재 기준으로 사용하는 결정은 합리적입니다. 품질 1위이며, Hybrid의 추가 비용이 작고 운영 지연도 0.14초 수준입니다.
단서	다만 43개 질문에서는 BGE-M3가 KURE+Hybrid, E5 Large+Hybrid, KoSimCSE+Dense보다 통계적으로 확실히 우수하다고 단정할 수 없습니다. 따라서 '확정 우승'보다 '현재 최선의 기준선'으로 표현해야 합니다.
보류	V3 Hybrid+Reranker는 배포하면 안 됩니다. 평균 nDCG가 낮고 CPU P95가 약 7.65초이며, 9개 임베딩에서 결과가 완전히 동일해 구현 구조를 재검토해야 합니다.
미완료	GTE Multilingual Base가 실패했으므로 엄밀히는 10개 모델 비교가 아니라 9개 모델 비교입니다. 최종 발표 전 GTE 재실행이 필요합니다.

합리성 점검

판정	내용	근거 수준
Hybrid가 전반적으로 우세	9개 성공 모델 평균 nDCG 0.831로 Dense 0.767보다 높고, 표준편차도 더 작음	강함
BGE-M3+Hybrid가 숫자상 1위	nDCG 0.876, Hit@1 74.4%. 하지만 상위 일부 조합과 신뢰구간이 겹침	중간
Reranker가 부적합	품질 하락, 7초대 지연, 임베딩별 결과 동일	강함
10개 모델 비교 완료	GTE 실패로 3개 조합 누락	성립하지 않음

1. 성능 비교: 어떤 조합이 실제로 좋았는가




상위 8개 조합

순위	조합	nDCG@5	Hit@1	Recall@5	P95
1	bge_m3 + v2_hybrid	0.876	74.4%	96.9%	136.9ms
2	kure_v1 + v2_hybrid	0.854	67.4%	96.9%	143.0ms
3	multilingual_e5_large + v2_hybrid	0.850	67.4%	96.9%	143.5ms
4	kosimcse_roberta + v1_dense	0.847	69.8%	96.9%	40.7ms
5	ko_sroberta_multitask + v2_hybrid	0.845	69.8%	95.7%	46.1ms
6	bge_m3 + v1_dense	0.843	65.1%	96.9%	136.7ms
7	qwen3_embedding_06b + v2_hybrid	0.838	67.4%	94.6%	128.5ms
8	kr_sbert_v40k + v2_hybrid	0.834	69.8%	98.1%	37.8ms

해석

- BGE-M3+Hybrid는 품질 1위입니다. KURE+Hybrid보다 nDCG가 0.022 높고, KoSimCSE+Dense보다 0.030 높습니다.
- KoSimCSE+Dense는 최고 품질 대비 nDCG 손실이 약 3.4%이지만 P95가 40.7ms로 약 3.4배 빠릅니다. 사용자가 결과를 즉시 확인해야 하는 UI에서는 실용적인 대안입니다.
- KR-SBERT+Hybrid는 Recall@5 98.1%로 상위 후보 중 가장 높고 P95 37.8ms로 빠릅니다. 다만 정답을 상위에 배치하는 nDCG는 0.834로 낮아, '누락 최소화' 목적에 더 적합합니다.
- BGE-M3+Hybrid의 P95 136.9ms는 서비스 검색 단계로는 충분히 낮지만, 이 값은 캐시가 활성화된 warm-query 기준입니다.

2. 방법론 검증: 결과가 논리적으로 타당한가



방법	평균 nDCG	평균 Hit@1	평균 Recall@5	중앙 P95	판단
v2_hybrid	0.831	65.1%	96.0%	53.7ms	기본값 권장
v1_dense	0.767	56.3%	92.4%	53.4ms	저지연 대안
v3_hybrid_reranker	0.753	48.8%	96.9%	7654.6ms	보류/재설계


통계적 해석

BGE vs KURE Hybrid	평균 차이 +0.022, 95% CI 0.000~0.052. BGE가 우세한 방향이지만 경계값이 0이므로 확정적 우위로 보기 어렵습니다.
BGE vs E5 Large Hybrid	평균 차이 +0.026, 95% CI -0.011~0.069. 신뢰구간이 0을 포함합니다.
BGE Hybrid vs KoSimCSE Dense	평균 차이 +0.030, 95% CI -0.016~0.083. 품질 차이가 명확하지 않습니다.
BGE Hybrid vs Qwen3 Hybrid	평균 차이 +0.039, 95% CI 0.004~0.080. 이 비교에서는 BGE가 통계적으로 우세합니다.

중요한 이상 신호

V3 결과의 동일성	9개 임베딩 모델에서 V3의 nDCG 0.7531, Hit@1 48.8%, Recall@5 96.9%가 모두 동일합니다. 이는 reranker가 초기 검색 점수를 완전히 덮어쓰거나 후보군이 사실상 동일해졌음을 강하게 시사합니다.
V3 지연	중앙 P95가 7.65초로 V1/V2보다 두 자릿수 이상 느립니다. CPU 배포 기준으로 실용적이지 않습니다.
GTE 실패	10개 모델 중 1개가 완전히 빠졌으므로 현재 결과표는 27개 조합만 유효합니다.
가중 종합점수	KoSimCSE+Dense가 균형 1위인 것은 설정된 품질 85%·속도 15% 가중치의 결과입니다. 가중치를 바꾸면 순위도 달라질 수 있으므로 절대적 사실이 아닙니다.

3. 실패 패턴과 다음 실험 계획



가장 어려운 질문

질문	유형	평균 nDCG	Top1 성공률	Top5 성공률
Q012	금액비교_대학생_재학증빙트랙	0.357	3.7%	77.8%
Q022	복지자격_소득미확인	0.517	18.5%	100.0%
Q008	금액비교_전체트랙_불가	0.527	0.0%	88.9%
Q023	복지자격_전국공고_지역무관	0.552	0.0%	96.3%
Q001	금액비교_다중트랙_비교	0.569	88.9%	100.0%
Q014	금액비교_다중트랙_비교2	0.573	14.8%	100.0%
Q018	금액비교_신청가능_기본케이스	0.618	22.2%	92.6%
Q033	소득미적용_고령자65세_완화모집	0.623	11.1%	100.0%

오류 패턴 해석

- Q012 대학생 재학증빙 트랙: Top1 성공률이 3.7%, Top5도 77.8%입니다. 일반 의미 검색만으로는 서류 청크와 소득·자격 청크의 우선순위를 안정적으로 구분하지 못합니다.
- Q008 전체 트랙 불가와 Q023 전국공고 지역무관: Top1 성공률이 0%입니다. 부정 조건, 지역 무관, 예외 규칙은 벡터 유사도보다 구조화 규칙과 메타데이터 필터가 더 적합합니다.
- 다중 트랙 금액 비교: 여러 income_table 청크를 동시에 비교해야 하므로 단일 Top1 검색보다 후보 청크 묶음 회수와 후처리 계산이 필요합니다.
- 어려운 질문 대부분은 '임베딩 모델을 더 크게 바꾸는 문제'보다 질문 유형 라우팅, chunk_type 보정, 구조화 필터로 해결할 가능성이 높습니다.

권장 로드맵

P0 - 현재 적용	BGE-M3 + V2 Hybrid를 기준으로 사용하고, KoSimCSE+Dense를 빠른 대안으로 유지합니다. 검색 결과는 Top-5를 LLM에 전달합니다.
------------	---

4. 적용 결정 및 검증 체크리스트

권장 로드맵

P0 - 현재 적용	BGE-M3 + V2 Hybrid를 기준으로 사용하고, KoSimCSE + V1 Dense를 빠른 대안으로 유지합니다. 검색 결과는 Top-5를 LLM에 전달합니다.
P1 - 검색 보정	질문을 금액 비교·서류·자격·지역·용어로 분류하고, income_table·document·notice_profile에 유형별 가중치를 적용합니다.
P1 - V3 재설계	reranker 단독 점수로 교체하지 말고 Hybrid 점수와 결합합니다. 후보 수와 모델을 줄이고 GPU 환경에서 다시 시험합니다.
P2 - 평가 확대	질문을 100~150개로 늘리고 GTE를 재실행합니다. 난이도, 경계값, 부정 조건, 복수 지역, 결측값 사례를 보강합니다.
P2 - 최종 RAG 평가	검색 지표 외에 LLM 출력의 근거 충실도, 인용 정확성, 서류 누락률, 조건부 서류 오판률을 함께 측정합니다.

최종 적용 체크리스트

기준선 고정	BGE-M3 + V2 Hybrid, Dense 0.65 + BM25 0.35 설정을 버전과 함께 기록
대안 검증	KoSimCSE + V1 Dense와 KR-SBERT + V2 Hybrid를 실제 UI 지연 조건에서 A/B 비교
미완료 보완	GTE 재실행 전에는 9개 모델·27개 성공 조합으로 표기
V3 비활성화	점수 결합·후보 다양성·GPU 재검증 전까지 운영 경로에서 제외
최종 검증	100개 이상 질문과 LLM 출력의 근거 충실도·누락률·조건부 오판률 평가

결론의 신뢰도

확실한 결론 Hybrid는 여러 임베딩 모델에서 평균 품질과 안정성이 가장 좋고, V3는 현재 CPU 환경에서 품질·지연 모두 부적합합니다.
잠정 결론 BGE-M3 + V2 Hybrid가 숫자상 1위이지만 상위 3~4개 조합과의 차이는 43개 질문만으로 확정하기 어렵습니다. '최종 우승'보다 '현재 기준선'이 정확한 표현입니다.

한 줄 결론 현재 데이터에서는 BGE-M3 + V2 Hybrid가 가장 합리적인 기본값입니다. 다만 상위 후보 간 우위는 아직 확정적이지 않고, V3 결과에는 구조적 이상 신호가 있어 재설계가 필요합니다.

출처: benchmark_report(2).html의 27개 성공 조합, 임베딩 요약, 방법 평균, 어려운 질문, paired bootstrap 결과를 재구성함.